

LAPORAN PROYEK AKHIR

Preprocessing dan Unsupervised Learning (K-Means Clustering pada Dataset Titanic)

Nama: Bagus Ferdianto

Mata Kuliah: Data Mining

NIM: 241011402995

Dosen: Agung Perdananto, S.Kom., M.Kom.

BAB I

Pendahuluan

1.1 Latar Belakang

Perkembangan teknologi menghasilkan data dalam jumlah yang sangat besar. Agar data tersebut dapat dimanfaatkan, diperlukan teknik analisis data. Salah satu teknik yang digunakan adalah **Clustering**, yaitu proses mengelompokkan data berdasarkan kemiripan karakteristik tanpa menggunakan label kelas (Unsupervised Learning).

Pada proyek ini digunakan algoritma **K-Means Clustering** untuk mengelompokkan data penumpang Titanic berdasarkan karakteristik tertentu. Sebelum proses clustering dilakukan, data terlebih dahulu melalui tahap **preprocessing** agar kualitas data menjadi lebih baik.

1.2 Tujuan

Tujuan proyek ini adalah:

- A. Melakukan preprocessing terhadap dataset Titanic.
- B. Menangani missing value.
- C. Menghapus data yang tidak diperlukan.
- D. Melakukan normalisasi data.
- E. Mengimplementasikan algoritma K-Means.
- F. Mengevaluasi hasil clustering menggunakan Elbow Method dan Silhouette Score.

BAB II

Dataset

Dataset yang digunakan

Dataset yang digunakan adalah **Titanic Dataset**.

Sumber dataset: <https://raw.githubusercontent.com/datasciencedojo/datasets/master/titanic.csv>

Dataset ini berisi informasi penumpang Titanic seperti:

- A. Survived
- B. Pclass
- C. Age
- D. Fare
- E. Sex
- F. Embarked
- G. dan atribut lainnya.

Dataset dipilih karena memiliki missing value sehingga cocok digunakan untuk proses preprocessing.

BAB III

Preprocessing Data

1. Mengecek Missing Value

Menggunakan: `df.isnull().sum()`

Hasil menunjukkan terdapat missing value pada:

- A. Age
- B. Cabin
- C. Embarked

```
df.isnull().sum()
0
PassengerId    0
Survived       0
Pclass         0
Name           0
Sex            0
Age          177
SibSp          0
Parch          0
Ticket         0
Fare           0
Cabin        687
Embarked       2
dtvpe: int64
```

2. Menghapus Kolom Cabin

Kolom **Cabin** memiliki terlalu banyak data kosong sehingga dihapus:

```
df = df.drop(columns=["Cabin"])
```

3. Mengisi Missing Value

Kolom **Age** diisi menggunakan nilai median:

```
df["Age"] = df["Age"].fillna(df["Age"].median())
```

Kolom **Embarked** diisi menggunakan nilai modus:

```
df["Embarked"] = df["Embarked"].fillna(df["Embarked"].mode()[0])
```

4. Menghapus Duplikasi

Data diperiksa menggunakan: `df.duplicated().sum()`

Hasil menunjukkan **tidak terdapat data duplikat**.

5. Encoding

Kolom kategorikal diubah menjadi numerik menggunakan One Hot Encoding:

```
pd.get_dummies()
```

Kolom yang diubah yaitu:

- A. Sex
- B. Embarked

6. Standarisasi


Normalisasi dilakukan menggunakan StandardScaler.: `StandardScaler()`

BAB IV

Implementasi Clustering

Menentukan Jumlah Cluster

Jumlah cluster ditentukan menggunakan **Elbow Method**.



Berdasarkan grafik tersebut dipilih beberapa kandidat jumlah cluster. Selanjutnya dilakukan evaluasi menggunakan Silhouette Score.


Silhouette Score

Hasil pengujian menunjukkan:

```
k = 2, Silhouette Score = 0.2514
k = 3, Silhouette Score = 0.1861
k = 4, Silhouette Score = 0.2290
k = 5, Silhouette Score = 0.2386
k = 6, Silhouette Score = 0.2961
k = 7, Silhouette Score = 0.3001
```

BAB V

Hasil Clustering



Visualisasi menunjukkan data berhasil dikelompokkan menjadi **7 cluster** berdasarkan karakteristik yang dimiliki setiap penumpang.

Analisis Cluster

Berdasarkan rata-rata setiap cluster diperoleh karakteristik sebagai berikut:

Cluster 0

- A. Didominasi penumpang berusia muda.
- B. Tarif sedang.
- C. Tingkat keselamatan tinggi.

Cluster 1

- A. Mayoritas kelas 1.
- B. Tarif tiket paling mahal.
- C. Tingkat keselamatan tinggi.

Cluster 2

- A. Didominasi laki-laki.
- B. Usia lebih tua.
- C. Tingkat keselamatan rendah.

Cluster 3

- A. Mayoritas kelas 3.
- B. Tarif murah.
- C. Tingkat keselamatan paling rendah.

Cluster 4

- A. Didominasi laki-laki.
- B. Tarif sedang.
- C. Usia sekitar 28 tahun.

Cluster 5

- A. Seluruh penumpang berasal dari pelabuhan Q.

Cluster 6

- A. Seluruh penumpang berasal dari pelabuhan S.
- B. Tingkat keselamatan sangat tinggi.

	Survived	Pclass	Age	SibSp	Parch	Fare	Sex_male	Embarked_Q	Embarked_S
Cluster									
0	0.868421	2.592105	12.575658	0.526316	1.052632	20.127139	0.394737	0.0	0.447368
1	0.855072	1.000000	31.694493	0.608696	0.681159	157.771558	0.246377	0.0	0.318841
2	0.289855	1.253623	42.655797	0.289855	0.144928	38.679680	0.985507	0.0	0.731884
3	0.098039	2.980392	18.882353	3.627451	2.254902	37.098859	0.450980	0.0	1.000000
4	0.080332	2.822715	28.077562	0.196676	0.060942	11.662209	0.914127	0.0	0.900277
5	0.389610	2.909091	28.032468	0.428571	0.168831	13.276030	0.532468	1.0	0.000000
6	0.949580	1.873950	32.558824	0.462185	0.361345	32.066387	0.000000	0.0	0.949580

BAB VI

Kesimpulan

Berdasarkan hasil preprocessing dan implementasi algoritma K-Means, dataset Titanic berhasil dikelompokkan menjadi 7 cluster. Tahapan preprocessing yang dilakukan meliputi penanganan missing value, encoding data kategorikal, serta standardisasi data. Evaluasi menggunakan Elbow Method dan Silhouette Score menunjukkan bahwa penggunaan 7 cluster menghasilkan nilai Silhouette Score tertinggi sebesar 0,3001. Visualisasi PCA memperlihatkan bahwa data berhasil terbagi ke dalam beberapa kelompok dengan karakteristik yang berbeda.

